

Thynk Unlimited

# CROPS VS WEEDS

W E E D D E T E C T I O N  
C V V S Y O L O


presented by:

**Ziv Peleg | Liron Odeni**





# Background



עשבים שוטים אשר מתחרים על משאבי הקרקע , המים  
והאור פוגעים באופן ניכר ביבול





חקלאים משתמשים ב "Blanket Spraying" אשר  
פוגע ב90% באזורים נקיים או ביבול עצמו



לשם כך נדרשת שיטה מתקדמת לאבחנה מדויקת בין  
עשב שוטה ליבול - במיוחד כאשר מדובר ביבולים בעלי  
דימיון מבחינת צבע \ מורפולוגיה.





"Lincoln Beet Dataset"

המאגר המקורי מכיל כ-4,413 תמונות בפורמט PNG  
תמונות RGB ברזולוציה גבוהה של 1920x1080

איזה מבין השיטות הקיימות לעיבוד תמונה תפיק  
תוצאות גבוהות יותר בזיהוי העשבים השוטים  
? Classical CV Or YOLO:



04

# Methods

## Classical Computer Vision

**Excess Green (ExG)**

**Otsu's Adaptive Thresholding**

**Morphological Operations**



## Deep Learning

**YOLOv11-Medium-Seg**


**1000 Photos Randomly**

**YOLOv11-Large-Seg**

**2000 Photos Randomly**




# Results - Classic




1. Original Image




3. Prediction Mask  
Prec: 0.96



5. Bounding Boxes  
Green=Truth, Red=Pred






נוכל לראות כי המודל מדויק אך לא רגיש מספיק. השלב הבא באימון צריך להתמקד בשיפור ה-Recall, אולי על ידי שינוי ה-Loss Function או הוספת Augmentations. צמחי הסלק בורחים לו מתחת לאף כי הוא לא היה מספיק בטוח בעצמו. הוא מפספס 80% מהאובייקטים האמיתיים (False Negatives).





# Results - YOLO (M)

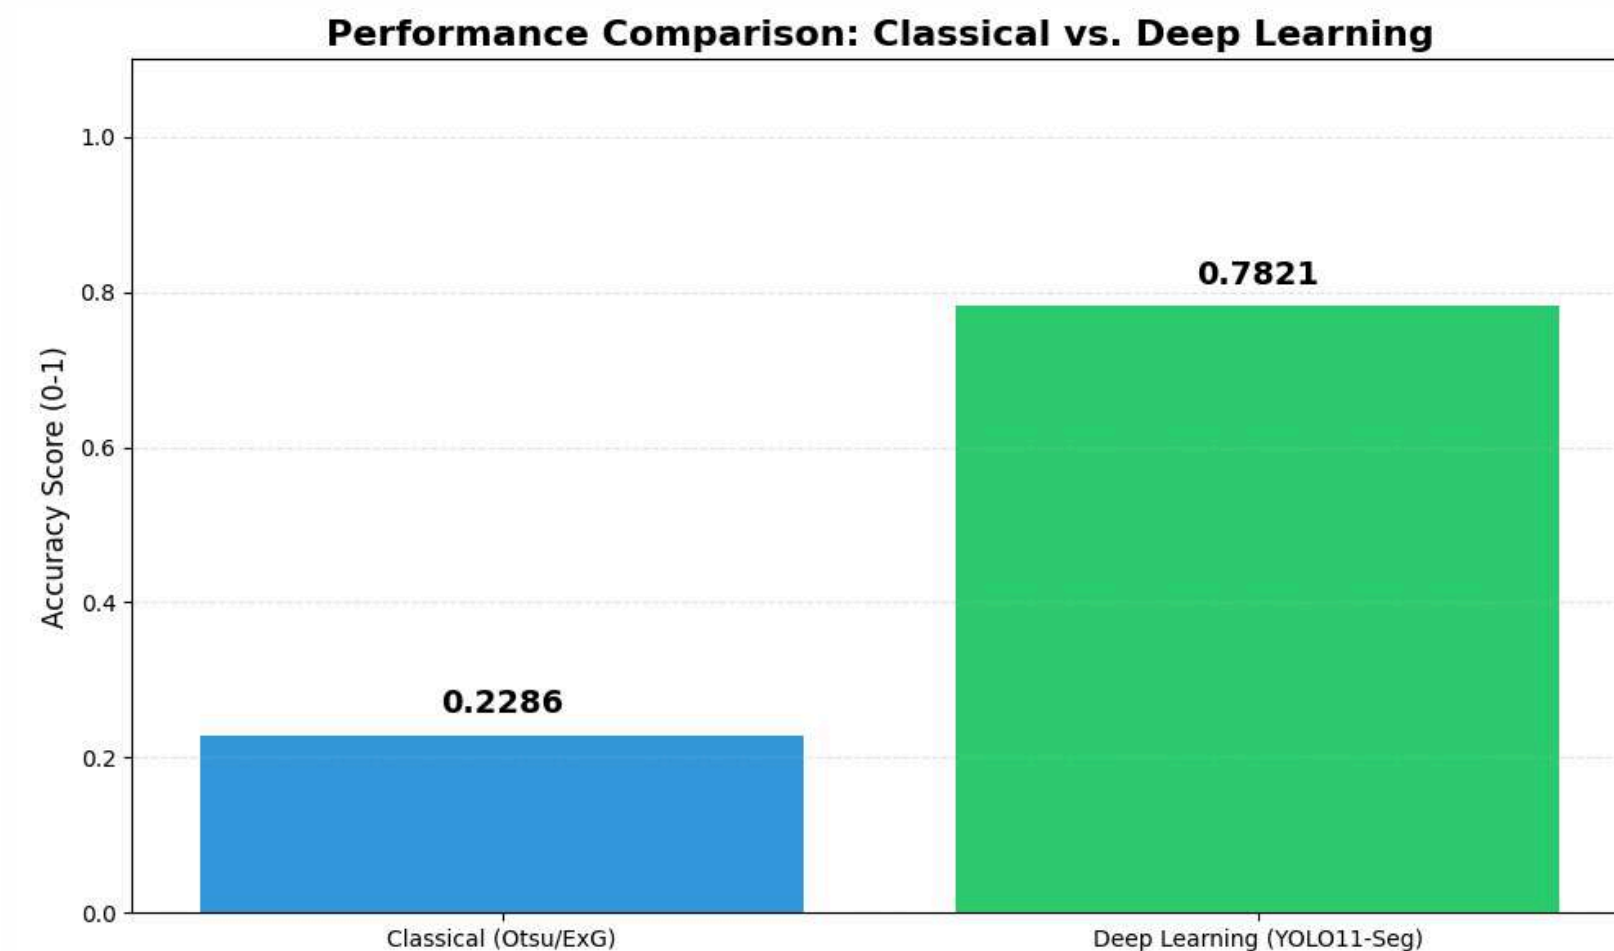


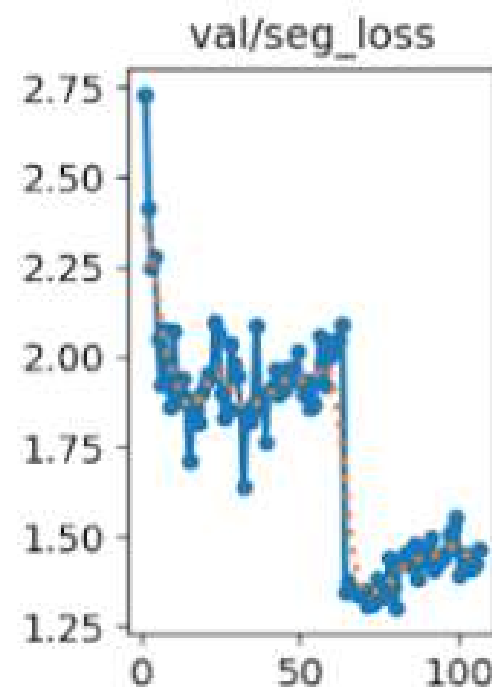
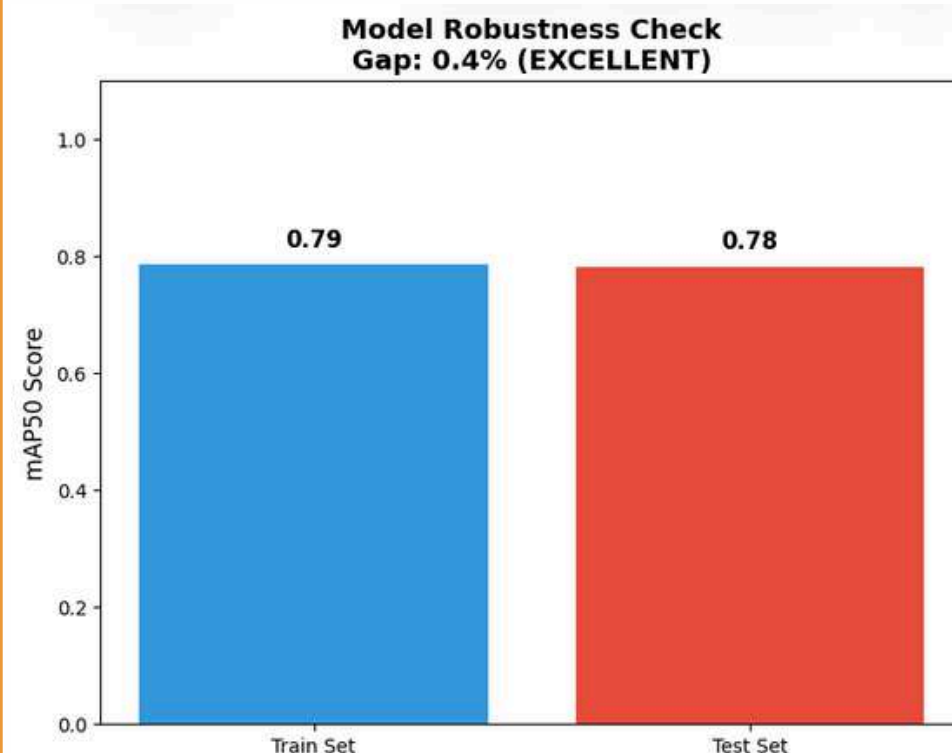
נוכל לראות כי .... בצד ימין (הגרפים): ניתן לראות תהליך התכנסות בריא. הגרפים העליונים מציגים את השיפור העקבי בדיוק הזיהוי (mAP), שמגיע לרמה גבוהה של כ-75%. במקביל, גרף ה-Loss למטה מציג ירידה חדה והתייצבות, מה שמוכיח שהמודל לא רק 'שינן' את החומר (Overfitting), אלא למד להכליל ולזהות צמחים גם בתנאים משתנים.



# So We did It (:

## Yolov11- Large

המודל הסופי השיג את התוצאות הטובות ביותר במחקר, עם ציון mAP50 של 0.782 ודיוק (Precision) של 0.794. נתונים אלו משקפים שיפור של כ-6.5 אחוזים בהשוואה למודל הביניים (שעמד על 0.734).





# Conclusions

09

## Classic Model

המודל הקלאסי שבנינו הוא בעל אופי "בטוח" (Conservative): הוא כמעט ולא טועה בזיהוי רעש כצמח (Precision גבוה מאוד), אך הוא מתקשה לתפוס את הצמח בשלמותו (Recall נמוך). בהקשר לחקלאות: זה מעולה אם המטרה היא ריסוס סלקטיבי בחומר יקר – אנחנו לא נבזבז חומר על אדמה סתם.

## סיכום ההשוואה

- במודל הקלאסי למרות האחוזי דיוק הגבוהים - המודל זיהה רק 22% משטח העלה האמיתי נתון ה-Acuuracy - אינו מייצג!
- **הוכחנו** שמעבר מראייה ממוחשבת קלאסית (Rule-based) ללמידה עמוקה (Data-driven) הוא הפתרון היחיד להתמודדות עם השונות הביולוגית בשדה (תאורה, גודל, הסתרות).

## Yolo Model

- **יציבות למידה והתכנסות בריאה** - המודל הציג תוצאות שעבור מערכת ריסוס, זה Acceptable אבל עבור מערכת קטיף רובוטית עדינה? זה עדיין לא שם. זהו ה-Trade-off הנוכחי של מודל Medium ברזולוציה הזו.
- מודל Medium vs Large - אמנם מודל ה-Large הציג את הדיוק המירבי גבוהה יותר, אך הוא כרוך בעלויות חישוב וזמן גבוהות. עבור החקלאי בשטח, מודל ה-Medium מסתמן כפתרון המעשי ביותר (Cost-Effective): הוא מציע פשרה מאוזנת המאפשרת דיוק מספק לפעולת הריסוס, תוך אפשרות לרוץ על חומרה זולה ונגישה יותר.





# Future Work

- הגדלת הדאטה סט וגיוונו : תמונות נוספות של הגידול , Augmentations , ועוד תמונות רבות של עשבים שוטים.
- **Active Learning**: במקום לתייג הכל ידנית, נשתמש במודל הנוכחי כדי לזהות תמונות שבהן הוא "מתלבט" (Confidence נמוך), ונתייג ידנית רק אותן. זה ייעל את תהליך הלימוד.
- **השוואת ארכיטקטורות**: בחינת מודלים כבדים יותר (XLarge) עם כמות תמונות גדולה יותר אם החומרה מאפשרת, להעלאת הביצועים.



**Thank You!**

