

השוואה כמותית בין עיבוד תמונה קלאסי למידה عمוקה (YOLO) לציהוי עשבים שוטים בגידולי סלק סוכר

(Quantitative Comparison between Classical CV and Deep Learning for Weed Detection in Sugar Beet)

האוניברסיטה העברית בירושלים הפקולטה לחקלאות, מזון וסביבה קורס: מבוא לעיבוד תמונה (71254)



מגישים: זיו פלאג 209087386, לירון עודני 207827086

06.02.2026

1. מבוא ורקע מדעי (Introduction)

עשבים שוטים (Weeds) המתחרים על משאבי הקרקע, המים והאור מהווים אחד הגורמים המרכזיים לפגיעה ביבול ובאיכות התוצרת החקלאית. ביום, ההתמודדות המקובלת עם מתבצעת לרוב באמצעות "רישום שמייכה" (Blanket Spraying) - יישום אחד וגורף של קוטלי עשבים על פני השדה כולו. גישה מסורתית זו מתגלה כבלתי, יעליה מבחינה כלכלית ומזיקה מבחינה סביבתית: מחקרים מצביעים על כך שעד כ-90% מחומר הדבירה מוחל-ul על אזורים נקיים מעשבים (קרקע חשופה) או על הגידול עצמו [1]. תופעה זו גוררת זיהום מי תהום, מעודדת התפתחות עמידות בקרב אוכלוסיות עשבים, ואף גורמת לעקה פיזיולוגית (Phytotoxicity) המעכנת את התפתחות הגידול התרבותי.

הפתרון המתבקש הוא מעבר לחקלאות מדיקת ולריסוס סלקטיבי (Spot Spraying), בו מערכת הריסוס מופעלת רק כנגד המטרה הספציפית. עם זאת, השימוש הטכנולוגי נתקל בחסם שימושו המכוון "Green-on-Green". בಗידולים כדוגמת סלק סוכר (Sugar Beet), העשב והיבול חולקים חתימה ספקטרלית (גון יירוק) דומה מאד, ולעתים קרובות אף יוצרים חפיפה מרחבית (Overlapping) המקשה על הפרדה ויזואלית פשוטה. בתרחיש מרכיב זה, אלגוריתמים בסיסיים המסתמיכים על הפרדת צבע (Color Thresholding) נוטים להיכשל.

מטרת הפרויקט: מטרת הפרויקט אינה מסתמכת רק בפיתוח כל' זיהוי, אלא מתמקדת ביצוע השוואה כמותית ואיכותית בין שתי פרדיגמות אלגוריתמיות לפתרון בעיית ה-Green-on-Green, תוך בחינת היתרון והחסרונות של כל גישה:

1. **עיבוד תמונה קלאסי (Classical CV):** גישה מבוססת חוקים (Heuristics) המשמשת באינדקס צבע (ExG), סף (Thresholding) ופעולות מורפולוגיות. גישה זו מייצגת פתרון "קל" מבחינה חישובית ואין דרושת אימון מקדים.

2. **למידה عمוקה (Deep Learning):** שימוש בYOLOv11 ליציאת סגמנטציה סמנטית (Segmentation Instance). בחרנו במשמעות הסגמנטציה (ולא רק זיהוי אובייקטים) מכיוון שהיא מספקת מידע ברמת הפיקסל על שטח הולה, נתן הクリיטי לחישוב מינון הריסוס המדויק.

במהלך הפרויקט נציג את תהליך הפיתוח האבולוציוני של מודל הלמידה העמוקה (החל ממודל Nano בסיסי ועד למודל Large), ננתן את הצללים בכל שלב, ונשווה את הביצועים הסופיים מול השיטה

הקלאסית במונחי דיק (UoIo/m), עמידות לרעש (Robustness) ויעילות חישובית.

2. מוד הנתונים (Database)

הפרויקט מtabסס על נתונים מתוך מאגר "Lincoln Beet Dataset", אשר נוצר על ידי המרכז למערכות אוטונומיות (S-CAS-L) באוניברסיטת לינקולן, בריטניה [2]. מאגר זה נאוסף במטרה לפתח רباتוטיקה קלאית לשיווג יבול מול עשבים (Crop/Weed Discrimination) בתנאי שדה אמיתיים ומאתגרים.

מאפיינים טכניים:

- מקור הנתונים: פורום והורד דרך פלטפורמת [3] Kaggle.
- תוכן: תמונות צבע (RGB) של סלק סוכר בשלבי גידול שונים, לצד מגוון עשבים בר האופיינים לשדות, בתנאי תאורה משתנים.
- רזולוציה: התמונות הן ברזולוציה גבוהה של 1080×1920 פיקסלים.
- פורמט תיוג: הנתונים מלאים בקבצי TIIG בפורמט VOC (XML, XML, הcoliims Bounding Boxes ו-SVG עבור כל צמח בתמונה).

עיבוד מקדים ואיזון נתונים (Data Pre-processing & Balancing)

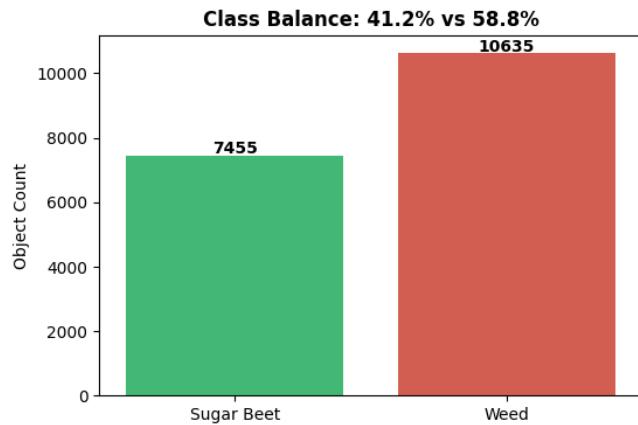
אחד האתגרים המרכזיים בעבודה עם נתונים חקלאיים גולמיים הוא חוסר איזון בין המחלקות (Class Imbalance). בניתוח ראשון של קבצי ה-XML, זיהינו פער משמעותי בכמות המופיעים בין סלק לעשב. ללא הטעבות, המודל עלול לפתח הטיה לטובה למחלקה השוללת (סלק), שכן סטטיסטיות "משתלים" לו להתעלם מהמחלקה שפחות רואים (עשב) כדי להשיג אחוז דיק גבוהים בצורה מלאכותית, מה שעלול להוביל לכישלון.

כדי להתגבר על כך, פיתחנו אלגוריתם סינון ייעודי (Custom Data Loader) שביצע את הפעולות הבאות:

- ניתוח סטטיסטי: סריקה של כל קבצי ה-XML ומספר האובייקטים לפני האימון.
- ייצור תת-קובוצה מאוזנת (Balanced Subset): דגימה מבודדת של תמונות כדי להבטיח שהיחס לא עובר את ה-40:60 בין מופיעי סלק למופיעי עשב.
- חילוקה לסטים: המאגר המאזן חולק באופן אקראי לשתי קבוצות:
 - סט אימון (Training Set): כ-1,600 תמונות (80%), המשמשות ללימוד המשקولات של

הרשות.

- ו סט אימויות (Validation Set): כ-400 תמונות (20%), המשמשות לבחינת ביצועי המודל על נתונים שלא ראה, לצורך ניטור Overfitting.



3. שיטות (Methods)

בפרויקט זה נקבעו בגישה השוואתית, כאשר המערכת הקלואסית משמשת כנקודות ייחוס (Baseline) לבוחינת הביצועים של מודל הלמידה העמוקה.

3.1. שיטה א': הגישה הקלואסית (Classical CV Pipeline)

בשיטה זו מימושנו אלגוריתם דטרמיניסטי (Rule-Based) המבוסס על הנחה כי ניתן להפריד את הצומח מהרקב על בסיס מידע ספקטRALI (צבע) בלבד. שרשרת העבודה כוללה:

1. **מרחב צבע ExG (Excess Green):** המרת תמונה ה-RGB למדד המציג את הרכיב הירוק תוך דיכוי הרכיבים האדומים והכחולים, לפי הנוסחה: $B - R - G = 2G$. טרנספורמציה זו יעילה להפרדת צמחיה מאדמה חומה/אדמדמה.

2. [5] **Otsu's Thresholding:** ביצוע סף (Threshold) אוטומטי. האלגוריתם מנתח את ההיסטוגרמה של תמונה ה-GEx וモציא את ערך הסף האופטימלי שմזען את השונות בתווך המחלקות (Intra-class variance), ובכך מפריד ביןארית בין "צמח" ל"רקע".

3. **עיבוד מורפולוגי:** יישום פעולות "סגירה" (Closing) ו"פתיחה" (Opening) עם גרעין (Kernel). שלב זה כועד לנוקות רעים נקודתיים (כגון אבני קטנות) ולסגור "חורים" שנוצרו בתווך אליו. העלים כתוצאה מהחזרת אור או צל.

2.3. שיטה ב': למידה عمוקה (YOLO11 - Deep Learning)

עבור הגישה המודרנית, בחרנו במודל YOLO11 [4] (You Only Look Once), המאפשר זיהוי אובייקטים בזמן אמיתי. התמקדנו במשימת סגמנטציה (Instance Segmentation), המספקת מסכה מדויקת לכל עלה, בניגוד לתיבה חוסמת (Bounding Box) רגילה שכוללת גם רקע מיותר.

תהליך הפיתוח האיטרטיבי (Iterative Development)

במהלך הפרויקט, חכלנו את המודל בשלושה שלבים עיקריים כדי להתמודד עם אתגרים שעלו:

1. שלב ראשוני (Nano): שימוש במודל הקטן ביותר (ח) לבדיקת היתכנות. שלב זה חשף את בעיית חסר האיזון בין נתונים (המודל התעלם מהעשבים).

2. שלב ביניים (Medium): מעבר למודל בינוני (ח') לאחר איזון הנתונים. המודל הראה שיפור, אך ערך מוקדם מדי עקב הגדרות סובלנות (Patience) מחמירות.

3. המודל הסופי (Optimized Large): כדי למקסם את הדיק, הגדכנו את התצורה הסופית הבאה:
○ מודל: (YOLO11-seg Large). מודל בעל קיבולת גבוהה למידת טקסטורות מורכבות, הקרטיות להבדלה בין סלק לעשב הדומה לו ויזואלית.

○ חזולציגות קלט: העלות הרזולציה מ- 640×640 פיקסלים. החלטה זו התקבלה כדי לשפר את הזיהוי של גבט עשבים זעירים, אשר ברזולציגה נמוכה נראים כרעש חסר צורה (אובייקטים קטנים נעלמים בדחיסה).

○ אסטרטגיית אימון: אימון ל-100 Epochs עם מנגנון עצירה מוקדמת (Early Stopping) עם סובלנות גבוהה (Patience=40), למניעת עצירה בטרם עת.

אגמנטציה והעשרה נתונים (Data Augmentation)

כדי למנוע התאמת יתר (Overfitting) ולשפר את יכולת הכללה של המודל לתנאי שדה משתנים, עשינו שינויים אקריאים על תמונות האימון:

- רוטציה ושיקוף: סיבוב ב- 25° ± מעליות והיפוך אנכי (Flip-Up-Down). הרצינן: לצמחים המצלומים מלמעלה (Top-down) אין כיווניות קבועה; עשוי יכול לצמוח בכלכיוון.
- Scale & Mosaic: שינוי קנה מידת ושיטת ה-Mosaic (חיבור 4 תמונות לאחת) כדי ללמד את המודל לזהות צמחים בכל גודל וצפיפות.

3.3. מדדי הערכתה (Evaluation Metrics)

השוואת הביצועים בוצעה באמצעות המדרדים הבאים:

- mAP50-95: מדד הסטנדרט בתחום, בודק את דיוק המודל בממוצע על פני סך כל הולר ומחמיר (מ-50% ועד 95% חפיפה), ובכך בודק לא רק "פגיעה" כללית אלא דורש שהחפיפה בין הסימון למציאות תהיה מושלמת.
- (Intersection over Union) IoU: מדד המכמת את החפיפה הגיאומטרית בין המסכה שחזה האלגוריתם לבין תיוג האמת (Ground Truth). מדד זה שימש להשוואה ישירה "ראש בראש" בין התוצאה הבינארית של השיטה הקלאסית לTYOLO.

4. תוצאות (Results)

פרק זה מתאר את התפתחות המודל לאורך הפרויקט. תהליך הפיתוח בוצע בצורה איטרטיבית (Iterative Process), כאשר הלקחים שהופקו מכישלונות בשלבים המוקדמים יושמו לשיפור המודל והנתונים בשלבים המתקדמים.

4.1. תוצאות גישת הראייה הממוחשבת הקלאסית (Baseline Results)

בשלב הראשון של הניסוי, בחנו את יעילותו של האלגוריתם הקלאסי המבוסס על מדד צבע (ExG) וסיגנום אוטומטי (Otsu). ניתוח כמותי על גבי תמונות המבחן הניב את המדרדים הבאים:

- מדד Intersection over Union (IoU): התקבל ציון נמוך של **0.228**, המעיד על חפיפה חלקלית בלבד בין הזיהוי לבין צורת הצמח האמיתית.
- רגישות (Recall): התקבל ציון נמוך של **0.228**. נתון זה מצביע על כך שהאלגוריתם הצליח לפחות רק כ-22% משטח הפנים של הצמח, תוך החמצה (False Negative) של רוב שטח העלה.

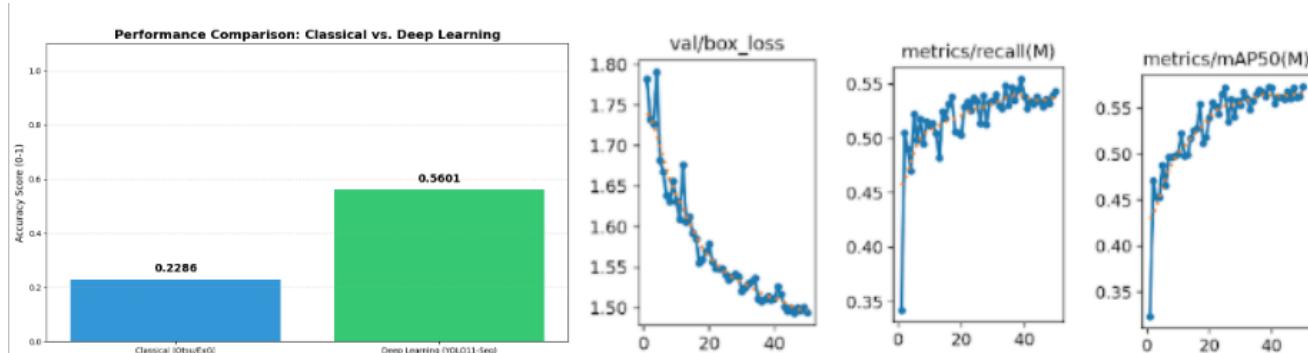
ניתוח התוצאות: הפער הקיצוני בין הדיוק המשולם לריגישות הנמוכה חשף את מגבלות השיטה: סף ה-Otsu נקבע בצורה שמרנית מדי. האלגוריתם הצליח לבדוק רק את ליבת העלים (האזורים הירוקים הבוהקים ביותר) אך כשל בזיהוי שולי העלים והאזורים המוציאים, אשר סוגו בטעות כרकע, מה שפוגע ביכולת לחשב במידוק את שטח הריסוס הנדרש (להרחבת ויזואלית, ר' נספח).

ג').

4.2. שלב א': מודל ראשוני (Baseline - YOLO Nano)

בשלב הראשון, הרכזנו מודל "קל" (Nano) כדי לבדוק היתכנות ראשונית על הנתונים הגולמיים.

- תצורה: YOLO11n-seg, 50 Epochs, ללא איזון נתונים. עם 1000 תמונות.
- תוצאות: המודל השיג ציון mAP50 נמוך של 0.56.
- ניתוח הכישלון: בוחינת התוצאות חשפה כי המודל זיהה אר וرك את מחלקה Beet-Weed (עשבי)
והתעלם לחלוטן מחלקה Sugar-Beet. בבדיקה של תהליכי היכנת הנתונים (Data Pipeline)
גילה שגיאת מיפוי טכנית (Mapping Error) במהלך המרת קבצי XML לפורמט
YOLO: חוסר התאמה (Mismatch) במהלך הטקסט המגדירה את שם המחלקה גרם לכך
שהכל המופיעים של סלק סוכר סוגים אחדים או נשטטו מהתהיליך האימון. כתוצאה לכך, המודל
אומן בפועל על מחלקה אחת בלבד.



- הגרפים מציגים את עיקומות הלמידה של הרצת המודל הראשוני (Nano). ניתן לראות כי בעוד שפונקציית המחיר (Loss) יורדת, מדדי הביצועים מציגים תמונה של למידה חסירה: מדדי mAP50 נגיע לרוויה (Saturation) מהירה ונעצר סביבה ערך 0.55. תופעה זו توأمמת את שגיאת המיפוי שנתגלתה, בה המודל נחשף רק למחלקה אחת מתוך השתיים. הירידה ב-Loss מעידה שהמודל הצליח למדוד את המאפיינים של המחלקה היחידה שהוצגה לו, אך ערך Recall הנמוך (כ-0.55) משקף את העובדה שהואفشل בזיהוי כל האובייקטים מהמחלקה החסירה (False Negatives), מה שמנע ממנו להגיע לביצועים גבוהים יותר.

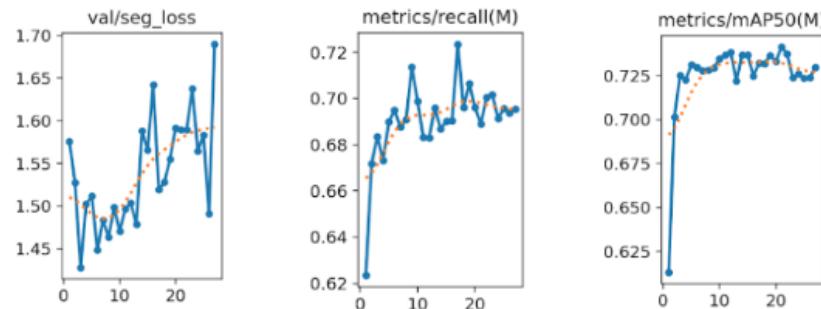
4.3. שלב ב': תיקון ואיזון (Medium Model)

בשלב זה, ביצענו תיקון של סקריפט המרת הנתונים כדי לכלול את שתי המחלקות כראוי. בנוסף, כדי למנוע הטיה עתידית שעשויה להיווצר עקב הפער הכמותי בין המחלקות, ביצענו איזון נתונים (Re-balancing) ליחס של עד 40:60.

- תצורה: שדרוג ל-`YOLOv1m-seg (Medium)`, 100 Epochs, מנגנון Stopping Early. עם 1000 תמונות.

- תוצאות: לאחר תיקון המיפוי ואיזון הדאטה, המודל הציג שיפור דרמטי והצליח לזהות את שתי המחלקות, עם ציון mAP50 של 0.734.

- ניתוח: האימון נעצר מוקדם מדי (ב-Epoch 27) עקב סבלנות נמוכה של מנגנון העצירה. הפער רם מיצה את יכולת



• הגרפים מציגים את תוצאות מודל הביניים (YOLO11-Medium). ניתן לראות במידה מהירה מאוד בשלבים הראשונים, כאשר המודל מזנק לדיק (mAP50) של כ-0.733 תוך פחות מ-10 epoch. עם זאת, ניתוח עקומות Validation Loss (שורה תחתונה) חושף חוסר יציבות: בעוד שהגיאת האימון ממשיכה לרדת, שגיאת האימוט מתחלילה להתקוודה (Fluctuate) ואינה מציגה שיפור עקבי. תופעה זו הפעילה את מנגנון העצירה המוקדם (Early Stopping) באפקט ה-27, ומעידה על כך שהמודל מיצה את יכולת הלמידה שלו בתצורה הנוכחית וכי נדרש רגולרייזציה נוספת (Data Augmentation) או מודל עמוק יותר כדי להמשיך ולשפר את התוצאות.

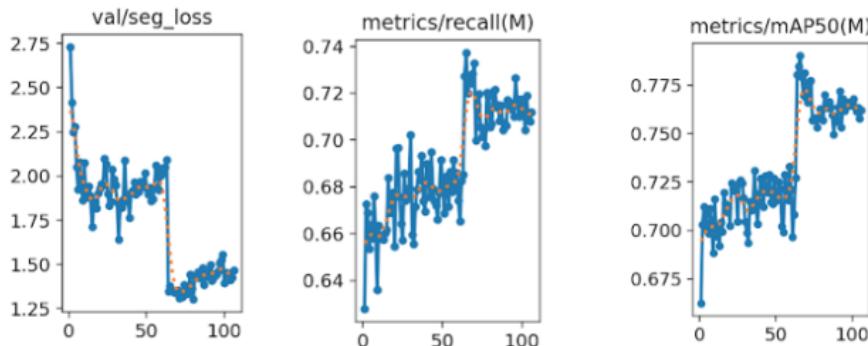
4.3. שלב ג': המודל הסופי (Optimized Large Model)

זהו המודל המתקדם ביותר שפותח בפרויקט, הכלול מודל כבד (Large), רזרוציה מוגדלת (960×960) ואגמננטציות גיאומטריות להתחומות עם מנת הצמחים למרחב. עם 2000 תמונות.

- ביצועים חמוטיים: המודל הסופי השיג את התוצאות הטובות ביותר במחקר, עם ציון mAP50 של

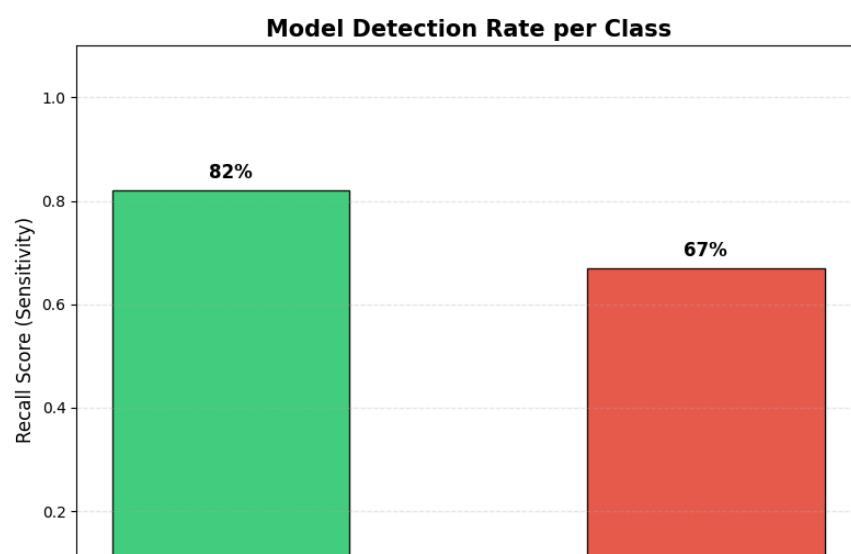
ודיק (Precision) של 0.794. נתונים אלו משקפים שיפור של כ-5.6 אחוזים בהשוואה למודל הביניים (שעמד על 0.734).

- ניתוח עקומות למידה (Loss Curves): גרפי ה-Loss Curves מראים ירידת עקבית ויציבה לאורר האימון, ללא תנודות חריגה המאפיינת מודלים לא יציבים. הפער הסופי בין ה-mAP Train ל-mAP Val עומד על 0.39% בלבד, נתון נמוך במיוחד המעיד על יכולת הכללה מעולה ולא סימני Overfitting (Generalization).



- הגרפים מציגים את תוצאות המודל הסופי (YOLO11-Large). בוגוד למודל הביניים, כאן ניתן לראות התכנסות יציבה וחלקה (Smooth Convergence): עקומות-loss (הן של האימון והן של האימונות) מציגות ירידת מונוטונית ועקבית לכל אורך הדרך, ללא תנודות(Fluctuations) שאפיננה את השלבים הקודמים. מدد הדיק (Gap) של הפער הסופי (mAP50) מטפס ומגיע לשיא של 0.782, אך הנתון המרשימים ביותר הוא הפער המזערי (Gap) של 0.39% בלבד בין ביצועי האימון לביצועי האימונות (כפי שהושב בסיום הריצה). פער מזערי זה משתקף ויוזאלית בגרפי loss, בהם קוווי האימון והאימונות יורדים בקצבות כמעט מלאה. התנהגות זו מוכיחה באופן מובהק כי המודל נמנע מ-Overfitting, וכי השימוש במודל (Large) בשילוב עם אוגמנטיות אפשר לו ללמידה הכללה אמיתית של המאפיינים הוויזואליים, ולא רק לשנן את דוגמאות האימון.

4.4. שיעור הזיהוי לפי מחלקה (Recall) כפי שנגזר ממטריצת הבלבול המנורמלת.



הגרף מציג את רגישות המודל (Recall) לכל מחלקה, בהתבסס על מטריצת הבלבול המנורמלת (ראו נספח ד'). המודל מפגין יכולת הכללה מרשימה עם 82% זיהוי ליבול (Sugar Beets), נתון המבטיח את שמיירתו של הרוב המוחלט של הסלק בשדה. מנגד, זיהוי העשבים (Weeds) עומד על 67% פער צפוי הנובע מרשונות הוויזואלית הגדולה בין סוגי העשבים ודמיונים לרקע הקרקע. למורת זאת, המודל מצילח לספק זיהוי טוב דבר המאפשר בסופו של דבר הדברת סלקטיבית יעילה.

4.5. השוואת מסכמת: קלאסי מול למידה عمוקה

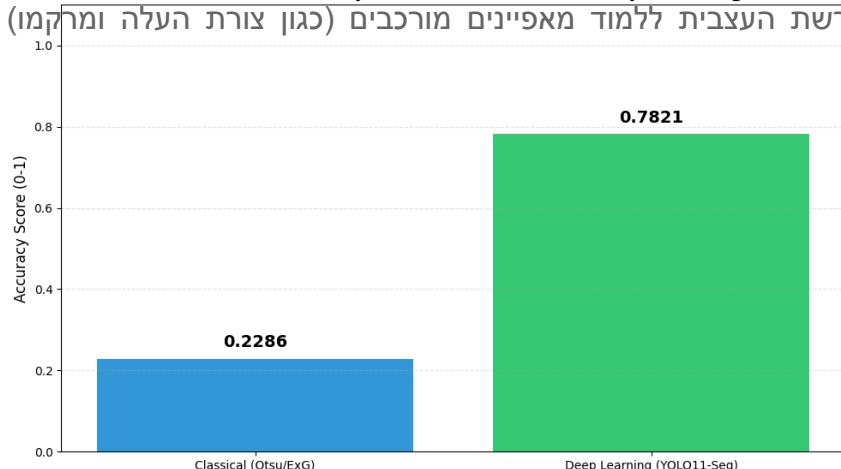
הטבלה להלן מרכזת את ההשוואה בין גישת הראייה הממוחשבת הקלאסית (Baseline) לבין מודל הלמידה העמוקה הסופי:

| מדד (Metric) | שיטה קלאסית (CV) | لמידה عمוקה (YOLO11-Large) | שיעור יחסי (Relative Score) |
|------------------------------|--------------------------------------|---|-----------------------------|
| דיק זיהוי (Diction Accuracy) | (mAP50) 0.22 | (mAP50) 0.782 | + 255% (Dramatic) |
| סוג הפלט (Output Type) | מסכה בינהרית גסה (Segmentation Mask) | סגןטציה סמנטית מדויקת (Semantic Segmentation) | - |
| זמן ריצה (Run Time) | מהיר מאוד (GPU) | מהיר (CPU) | - |
| עמידות (Robustness) | גבוהה (לומד טקסטורות) | גבוהה (רגיש לתאורה) | - |

מסקנה מהנתוצאות: בעוד שהשיטה הקלאסית הצלחה לבצע הפרדה גסה בין "ירוק" ל"לא-ירוק", היא כשלה באבחנה הדקה בין סוגי הצמחים. לעומת זאת, מודל ה-YOLOvdY הדגים יכולת סיווג גבוהה, הנובעת

Performance Comparison: Classical vs. Deep Learning

מיכולת הרשת העצבית ללמידה מאפיינים מורכבים (כגון צורת העלה ומפרקתו) ולא להסתמך על צבע בלבד.



5. דיוון (Discussion)

מטרת הפרויקט הייתה לבחון את היעילות של מודלים מבוססי למידה عمוקה (Deep Learning) בפתרון בעית ה-Green-on-Green, בהשוואה לשיטות עיבוד תמונה מסורתיות. ניתוח התוצאות מצביע על פער ביצועים מובהק לטובות גישת הלמידה העמוקה. בחלק זה ננתן את הסיבות לפער זה ואת המשמעות הנגזרות ממנו.

5.1. ניתוח מגבלות השיטה הקלאסית

השיטה הקלאסית (ExG/Otsu) הציגה ביצועים נמוכים באבחנה בין סלק לעשב, למرات שהצלחה לבזבז את הצמחיה מהקרקע. כישלון זה נובע מחפיפה ספקטרלית (Spectral Overlap): האלגוריתם משתמש אך ורק על ערכי הפיקסל (צבע). מכיוון שם הסלק וגם העשב חולקים גוונים ירוקים דומים מאוד, אין סף (Threshold) ייחיד שיכל להפריד ביניהם. בנוסף, השיטה הרatta רגישות גבוהה לתנאי תאורה – צללים שהוטלו על העלים גרמו לשינוי בערכי ExG ולסיווג שגוי כרקב (False Negative), מה שמעיד על רוביוטיות נמוכה בתנאי שדה משתנים.

5.2. עליונות מודל OLO11 והסביר הלמידה

לעומת השיטה הקלאסית, מודל ה-OLO11 הדגים יכולת סיוג גבוהה. הסיבה לכך נעוצה ברשות העצבית (CNN): המודל אינו "מסתכל" רק על הצבע, אלא לומד מאפיינים מרחביים (Spatial Features) היררכיים.

- בשכבות הראשונות, הרשת לומדת לזהות קצנות וגבולות.
- בשכבות העמוקות, הרשת לומדת לזהות צורות מורכבות וטקסטורות. המודל הצלח "להבין" שעלי סלק מתאפיינים במבנה רחב, עגול ובעל שטח פנים גדול, בעוד העשבים מתאפיינים במבנה צר, מחודד ומשוון. יכולת זו, המכונה למידה מורפולוגית, היא שמאפשרת את ההפרדה גם כאשר הצבע זהה לחלווי.

5.3. ניתוח הכללה ו-(Overfitting)

אחד השאלות המרכזיות בפרויקט הייתה האם המודל מצליח להכליל (Generalize) לנתחים חדשים או

שהוא פשוט "משנן" את דוגמאות האימון. השוואת הביצועים בין סט האימון (Train) לסט האימות (Validation/Test) במודל הסופי הראתה פער (Gap) קטן ויציב.

תוצאה זו, המוגובה בגרפי Loss, מעידה על כך שלא התרחש Overfitting ממשמעותי. אנו מייחסים את ההצלחה זו לשני גורמים בקוד שלנו:

1. איזון הנתונים: מנע הטיה למחלקה השלטת.
2. אוגמנטציה אגרסיבית: השימוש ברוטציות (25^{\pm}) והיפוכים לימד את המודל להתמודד עם האוריינטציה האקראית של הצמחים בשדה, והכריח אותו למדוד מאפיינים אינוריאנטיים (בלתי תלויים בכיוון).

5.4. הקשר לספרות ומחקרים דומים

ממצאים אלו בקנה אחד עם הספרות המקצועית העדכנית בתחום החקלאות המד"יקת [1], המצביע על כך ששיטות מבוססות ספ. צבע מוצו עד תום, וכי העתיד טמון במערכות לומדות. הספרות מדגישה כי האתגר העיקרי כיום אינו חזיהו עצמו, אלא ייעילות החישוב בזמן אמיתי. הבחירה שלנו במודל משפחתי OYO (הידעו במהירותו) בשילוב עם משימת סגמנטציה מוכיחה היתכנותו ליישום רובוטי שדורש גם מהירות וגם דיוק בחישוב שטח הריסוי.

6. מסקנות (Conclusions)

לאחר בוחנה השוואתית בין עיבוד תמונה קלאסי לבין מודלים של למידה عمוקה לזהיה עשבים בסלק סוכר, הגיענו למסקנות הבאות:

1. **יתרון Deep Learning בבעיית Green-on-Green:** השיטה הקלאסית (Otsu) יعلاה להפרדת צמח מדומם, אך אינה מתאימה לשימוש בשדה בו העשב והיבול דומים ויזואלית. מודל OYO הוכיח כי ניתן להגיע להפרדה מדויקת גם ללא הבדלי צבע מובהקים, בזכות יכולת הרשת העצפית למדוד מאפייני צורה וטקסטורה מורכבים.
2. **חשיבות הסגמנטציה ליישום חקלאי:** הבחירה במודל סגמנטציה (-seg) ולא רק בזיהוי אובייקטים (-det) התרברה כקריטית. המסכה המדעית מאפשרת לחשב את שטח העליה

בפועל, נתון הכרחי לחישוב מינון הריסוס המדוייק ולמצעור השימוש בכימיקלים, בנייתם לתיבת חוסמת (Bounding Box) שכוללת גם רקע מיותר.

3. טרייד-אוף (Trade-off) בין משאבים לביצועים:

- אמנים מודל ה-Large הציג את הדיק המירבי (mAP50) 0.782, אך הוא כרוך בעליות חישוב וזמן גבירות. עבור החקלאי בשטח, מודל ה-Medium מסתמן כפתרון המעש ביותר (Cost-Effective): הוא מציע פשרה מואצת המאפשרת דיק מספק לפועלות הריסוס, תוך אפשרות לרוץ על חומרה זולה ונגישה יותר.
 - עבור דיק מקסימלי, מודל ה-Large הוא המומלץ. הוא מגין רובוטיות גבוהה יותר לשינוי גודל ומנה, במחair של זמן חישוב מעט ארוך יותר (אך עדין בגדיר זמן אמיתי).
4. המלצה למחקר עתידי: להמשך הפיתוח, אנו ממליצים להרחב את מאגר הנתונים כך שיכלול מגוון רחב יותר של מיני עסקים, וכן לבחון את עמידות המודל בתנאי קיצון (כגון שימוש ישירה חזקה או צילוםليل עם תאורה מלאכותית), כדי להבטיח מערכת מבצעית מלאה.

7. ביבליוגרפיה (Bibliography)

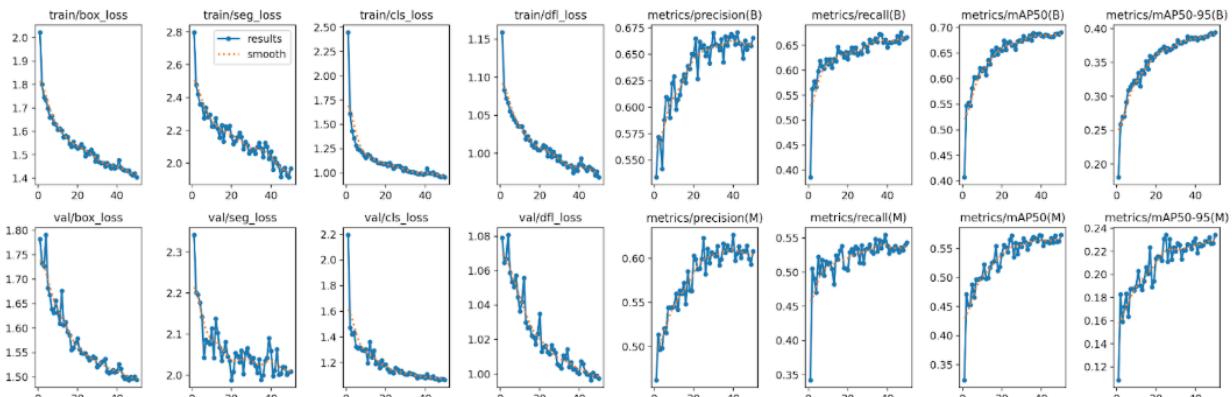
- [1] Slaughter, D. C., Giles, D. K., & Downey, D. (2008). Autonomous robotic weed control systems: A review. *Computers and Electronics in Agriculture*, 61(1), 63-78.
- [2] Skoczen, A., et al. (Lincoln Centre for Autonomous Systems). (2018). *The Lincoln Beet Dataset*. University of Lincoln, UK.
- [3] Kaggle Dataset: "Amiran Mkrchyan - Crop/Weed Field Image Dataset". Available at: <https://www.kaggle.com/datasets/amiranmkrchyan/amiran>
- [4] Jocher, G., et al. (2024). *Ultralytics YOLO (Version 11)*. Available at: <https://github.com/ultralytics/ultralytics>
- [5] Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1), 62-66.

נספחים (Supplementary Material)

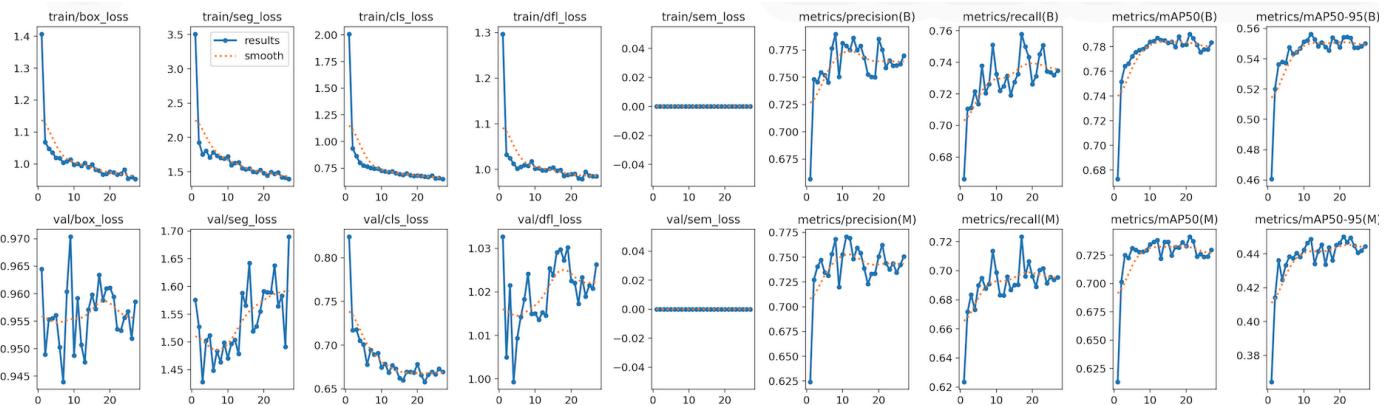
- קוד הפרויקט: מצורף קישור למחברת Google Colab המכילה את כל שלבי הניסוי, הקוד וההרצות:
<https://colab.research.google.com/drive/1pufwWD5643nWlzwIQAPW58x9AjOUkFpl?usp=sharing>
- GitHub link:
<https://github.com/LironOd/Crop-Weed-Segmentation-Algorithm>

נספח א: גרפים של מודלים.

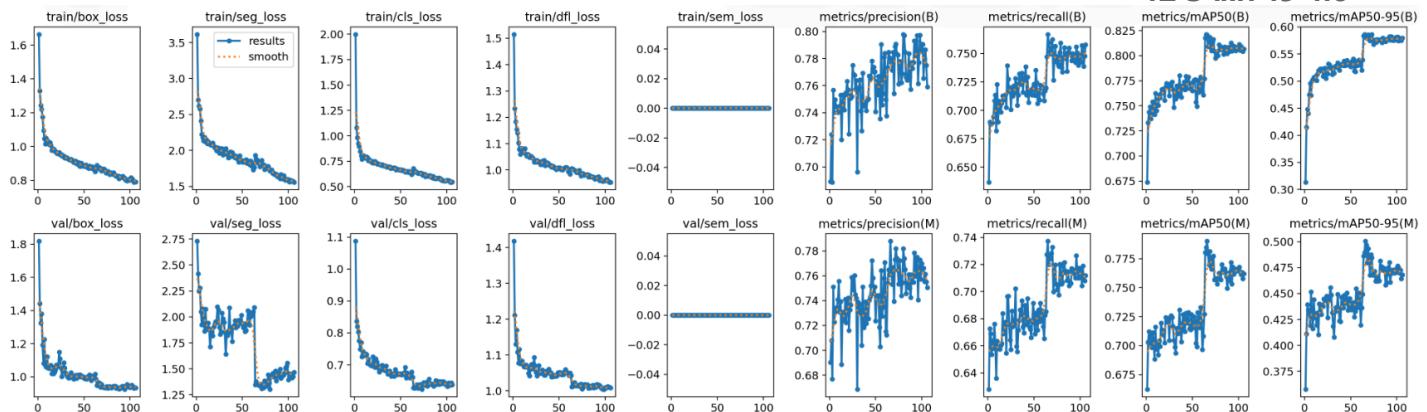
כל הגրפים:



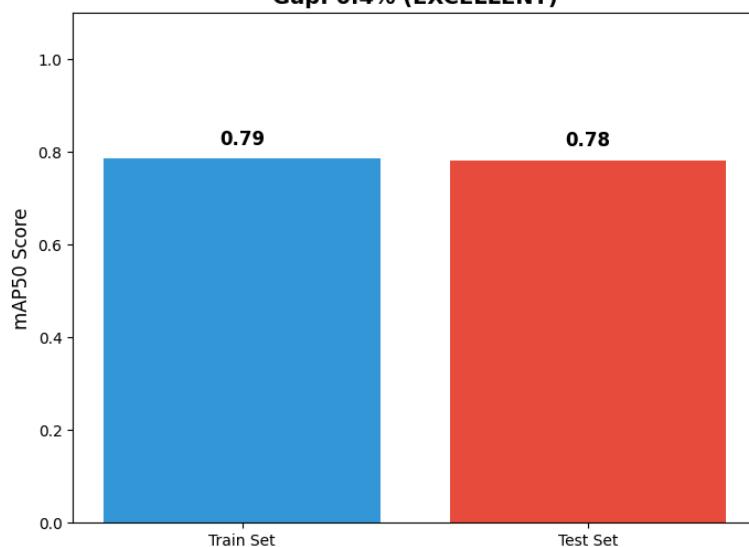
כָּל הַגְּרָפִים: 4.2



כָּל הַגְּרָפִים: 4.3



Model Robustness Check Gap: 0.4% (EXCELLENT)



- נספח ב': דוגמאות ויזואליות לنتائج הסיווג והסגמנטציה (Qualitative Results)

נספח זה מציג דוגמאות נבחרות מתוך סט האימות (Validation Set), המדגימות את יכולות המודל הסופי (YOLOv11-Large) בתרחישי אמיתי. התמונות להלן עברו סינון סף (Confidence) קפדי, כך שמדוברת אך ורק דיותקציות בעלות רמת ביטחון (Thresholding) של 80% (Score) בגובהה מ-80%.

בתמונות ניתן להבחין ביכולות הבאות:

1. הפרדת Green-on-Green: יכולת המודל להבחין בין סלק סוכר (Sugar Beet) לבין עשב (Weed) גם כאשר הגוונים כמעט זהים, בהסתמך על מאפיינים מורפולוגיים (צורת העלה) וטקסטורה.

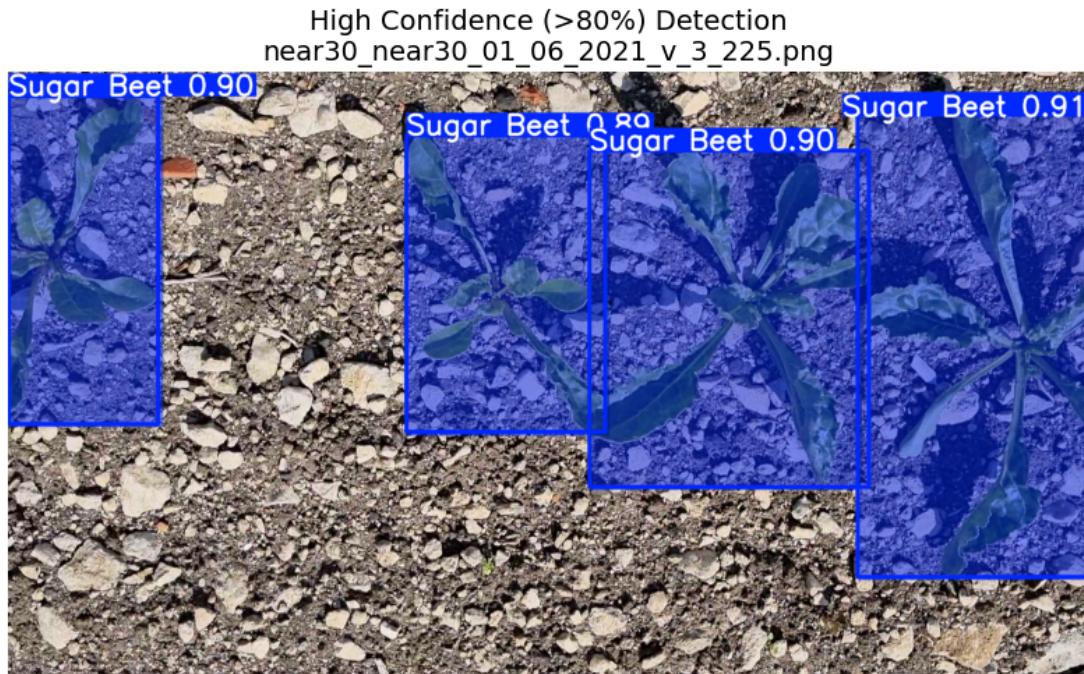
2. דיק הסגמנטציה (Instance Segmentation): המסקות (Masks) הצבעוניות עוקבות במדויק אחר מתאר העלה (Contour), ולא מסתפקות בתיבה חסומה (Bounding Box) מרובעת. דיק זה קרייטי לחישוב שטח העלה ולריסוס סלקטיבי.

High Confidence (>80%) Detection
near30_near30_21_05_2021_v_5_4.png



תמונה 1: זיהוי והפרדה (Classification & Separation). המודל מזהה את צמח הסלק (Sugar Beet) במרכז התמונה ומפריד אותו מהعشבייה הסובבת. ניתן לראות כי המסקה הצבעונית מכסה

היתב את שטח העלה, והסיווג מתבצע ברמת ביטחון גובהה (מעל 0.8).



תמונה 2: התמודדות עם גודלים משתנים (Scale Invariance). המודל מדגים יכולת לזהות נבטים קטנים או חלקו צמח, ולא רק צמחים בגודרים גדולים. דיק זה חיוני לטיפול מוקדם בעשבי שוטים עוד בשלב הגדילה הראשונית.

• נספח ג': ניתוח ביצועי השיטה הקלואסית (Baseline Analysis)

נספח זה מציג את התוצאות הכמותיות והאיכותיות של אלגוריתם הראייה הממוחשבת הקלואסית (ExG + Otsu Thresholding).

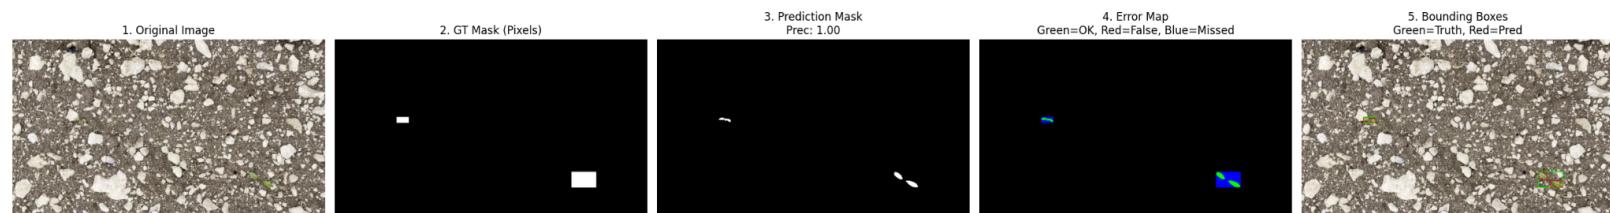
1. מדדים כמותיים (Quantitative Metrics): בבדיקה שנערכה על תמונה מייצגת מאוסף הנתונים, התקבלו התוצאות הבאות:

- IoU (Intersection over Union): 0.2286
- Precision (דיק): 1.0000 (מושלם)

- Recall (رجישות): 0.2286 (نمוך)
- Accuracy (دیک کلی): 0.9935 (نحوٰ زا مطعا، شکن هرچوں همچوٰش شل ہتمونہ ہو ارکع/ارضہ، والگوریتم ڈیک بزیہی الرکع).

نیتھوٰ ہمسپریپ: ہپور العظوم بین Precision ہموشلم (1.0) لے-اے Recall ہنمور (0.22) معید ہی الگوریتم ہی سلکٹیبی مدی۔ ہسپ (Threshold) شنکبے علی یڈی شیٹ نتس Otsu ہیہ گبہ، کر شرک ہتلکیم ہبواکیم وہیروکیم بیوتھر شل ہعلہ ڈھو، بعد شولی ہعلیم وہاڑویم ہموزلیم سووگو بتعوٰتھ رکع.

نیتھوٰ یزوالی (Qualitative Analysis): ہتمونہ لہل میزیگا ات شلبی ہعیبود وہشگیاوت شنوزرا:



نوسخ د': متریذت الببلو المنورملت (Normalized Confusion Matrix)

